



SAĞLIK ANALİTİĞİNDE MAKİNE ÖĞRENMESİ YÖNTEMLERİYLE MEME KANSERİ TESPİTİ

**Gülfiz POYRAZ
6006179**

Prof. Dr. Orhan ER

24.5.2025

İÇİNDEKİLER

- Amaç
- Veri Seti
- Kullanılan Kütüphaneler
- Keşifsel Veri Analizi (EDA)
- Veri Ön İşleme
 - IQR (Çeyrek Açıklığı) yöntemi
 - StandardScaler()
 - Korelasyon matrisi
 - Isı haritası (heatmap)
- Makine öğrenmesi modelleme yaklaşımı
- Makine öğrenmesinde neden eğitim ve test çalışması yapılır?
- Kullanılan Algoritmalar
 - Lojistik Regresyon (LR)
 - K-Nearest Neighbors (KNN) yöntemi
 - Decision Tree (DT)
 - Random Forest (RF)
 - Gaussian Naive Bayes (NB)
 - Support Vector Machine (SVM)
- Önem skoru
- Model Performans Karşılaştırması
- Confusion Matrix
- ROC Eğrileri ve AUC değerleri
- Sonuçlar ve Yorumlar
- Gelecek Çalışmalar
- Kaynakça



Amaç

Bu çalışmanın amacı, Wisconsin Meme Kanseri veri setindeki sekiz adet tümör morfolojisi özelliğini (çevre, alan, pürüzsüzlük, kompaktlık, konkavite, konkav nokta sayısı, simetri ve fraktal boyut) kullanarak malign ve benign vakaları yüksek doğrulukla ayırt edebilen makine öğrenmesi modelleri geliştirmektir. %80-%20 eğitim-test bölme, IQR temelli aykırı değer temizliği, label encoding ve StandardScaler ile hazırlanan veriler üzerinde Logistic Regression, K-Nearest Neighbors, Decision Tree, Random Forest, Gaussian Naive Bayes ve Support Vector Machine algoritmalarını karşılaştırarak en güçlü sınıflandırıcıyı belirlemek; elde edilen modeli klinik karar destek sistemlerine entegre edilebilecek, erken teşhiste zaman kazandırıp, radyoloji/patoloji yükünü azaltma potansiyeli güvenilir bir prototip olarak sunmaktır.



Veri seti:

Veri Seti Sütun Adları (İngilizce - Türkçe)

İngilizce Sütun Adı	Türkçe Karşılığı
diagnosis	Tanı
radius_mean	Yarıçap (Ortalama)
texture_mean	Doku (Ortalama)
perimeter_mean	Çevre (Ortalama)
area_mean	Alan (Ortalama)
smoothness_mean	Pürüzsüzlük (Ortalama)
compactness_mean	Sıkılık (Ortalama)
concavity_mean	Çukurluk (Ortalama)
concave points_mean	Çukur Nokta (Ortalama)
symmetry_mean	Simetri (Ortalama)
fractal dimension mean	Fraktal Boyut (Ortalama)

Bu sayısal verilerden yola çıkarak geliştirilen makine öğrenmesi modelleri, hedef değişken olan tani sütunundaki değerleri (kanser / kanser değil) tahmin etmeyi amaçlamaktadır. Veri setindeki tani sütununda ('tani'), kanserli hastalar 'M', kanser olmayanlar ise 'B' olarak etiketlenmiştir. Bu kategorik ifadeler, modelin anlayabileceği şekilde sayısal biçime dönüştürülmüştür:

'B' → 0 (kanser değil),

'M' → 1 (kanser).

Böylece hedef değişken olan tani, sınıflandırma modelleri tarafından işlenebilir hale getirilmiştir.

Meme Kanseri Wisconsin (Tanı) Veri Seti

Veri seti, Wisconsin Üniversitesi'nden sağlanan "Breast Cancer Wisconsin (Diagnostic)" verisinden alınan 529 gözlem ve 9 sütundan oluşmaktadır. Aşağıda orijinal İngilizce sütun adları ile Türkçe karşılıkları verilmiştir. Veri setindeki 8 özellik; tümörün boyutu, şekli, pürüzlülüğü, kompaktlığı, konkavitesi (çukurluk), konkav nokta sayısı, simetrisi ve fraktal boyutu gibi biyolojik ve histopatolojik ölçümleri içerir. Bu sayısal değerler; meme dokusundaki sertlik, çukurluk ve simetri bozukluğu gibi klinik belirtilerin makine öğrenmesi modellerine girdi olarak tanımlanmasını sağlar.


cevre_ortalama	alan_ortalama	puruzsuzluk_ortalama	kompaktlik_ortalama	konkavite_ortalama	konkav_nokta_sayisi_ortalama	simetri_ortalama	fraktal_boyut_ortalama	tani_1
132,90	1326,00	0,08	0,08	0,09	0,07	0,18	0,06	kanser
130,00	1203,00	0,11	0,16	0,20	0,13	0,21	0,06	kanser
134,70	1299,00	0,09	0,13	0,15	0,10	0,22	0,05	kanser
137,80	1308,00	0,10	0,17	0,21	0,13	0,21	0,06	kanser
93,77	629,80	0,10	0,12	0,15	0,06	0,19	0,06	kanser
103,40	716,90	0,10	0,21	0,26	0,09	0,21	0,07	kanser
131,20	1261,00	0,10	0,10	0,14	0,10	0,18	0,06	kanser
108,30	858,10	0,08	0,10	0,09	0,05	0,16	0,06	kanser
79,08	455,80	0,11	0,10	0,03	0,03	0,19	0,06	kanser
73,34	409,00	0,10	0,05	0,03	0,02	0,19	0,06	kanser
72,49	399,80	0,09	0,05	0,03	0,02	0,16	0,06	kanser değil
85,69	566,20	0,07	0,04	0,00	0,00	0,14	0,05	kanser değil
85,31	538,90	0,09	0,08	0,09	0,03	0,18	0,06	kanser değil
63,95	298,30	0,10	0,10	0,06	0,03	0,19	0,06	kanser
84,88	538,40	0,09	0,07	0,03	0,03	0,16	0,06	kanser

i_ortalama	fraktal_boyut_ortalama	tani_1
18	0,06	1,00
21	0,06	1,00
22	0,05	1,00
21	0,06	1,00
19	0,06	1,00
21	0,07	1,00
18	0,06	1,00
16	0,06	1,00
19	0,06	1,00
19	0,06	1,00
16	0,06	0,00
14	0,05	0,00
18	0,06	0,00
19	0,06	1,00
16	0,06	1,00

Tablo 1 'Tani'sütunun'0 ve 1' dönüşümü

Kullanılan kütüphaneler

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from openpyxl import load_workbook
from openpyxl.worksheet.table import Table, TableStyleInfo
from openpyxl.utils import get_column_letter
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder, StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.neighbors import KNeighborsClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC
from sklearn.neural_network import MLPClassifier
from sklearn.metrics import confusion_matrix, roc_curve, auc
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression, RidgeClassifier, SGDClassifier, PassiveAggressiveClassifier
from sklearn.ensemble import (RandomForestClassifier, GradientBoostingClassifier, AdaBoostClassifier, ExtraTreesClassifier)
from sklearn.naive_bayes import GaussianNB, BernoulliNB, MultinomialNB
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis, QuadraticDiscriminantAnalysis
from sklearn.gaussian_process import GaussianProcessClassifier
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, roc_auc_score
from scipy import stats
from sklearn.metrics import classification_report
```




Keşifsel Veri Analizi (EDA)

Modelin doğru, dengeli ve güvenilir sonuçlar üretebilmesi için kritik bir adımdır. Bu süreçte verideki eksik, anlamsız veya uç (aykırı) değerler tespit edilip temizlenir; kategorik değişkenler dönüştürülerek makine öğrenmesinin işleyebileceği sayısal forma getirilir. Ayrıca dengesiz sınıf dağılımı düzeltilerek modelin her sınıfa eşit hassasiyet göstermesi sağlanır.

Veri setin incelendiğinde içerisinde eksik verisi bulunmamaktadır ve 'int' sayılarından oluşmaktadır.

```
cevre_ortalama      0
alan_ortalama       0
puruzsuzluk_ortalama 0
kompaktlik_ortalama 0
konkavite_ortalama  0
konkav_nokta_sayisi_ortalama 0
simetri_ortalama    0
fraktal_boyut_ortalama 0
tani                0
dtype: int64
```



Tüm özellikler için yan yana çizilmiş boxplot'lar incelendiğinde, her bir değişkenin dağılım aralığı ve uç değer profili kolayca görülebilir. Boyut temelli ölçümler olan `cevre_ortalama` ve `alan_ortalama`, daha geniş bir yayılım sergilerken (özellikle `alan_ortalama`'da 2500'e kadar uzanan uç değerler), şekil-temelli özellikler (`pürüzsüzlük`, `kompaktlık`, `konkavite` vb.) dar bir değer aralığında toplanıyor. Örneğin `konkavite_ortalama` ve `konkav_nokta_sayisi_ortalama`, kutu sınırlarının üzerinde birkaç uç nokta barındırıyor, bu da veri setindeki bazı tümörlerin çukurluk açısından diğerlerinden belirgin biçimde farklılaştığını gösterir. `Simetri_ortalama` ve `fraktal_boyut_ortalama` ise hemen hemen simetrik ve dar aralıklı dağılımla, çok az aykırı değer içeriyor. Genel olarak, boyut ve çukurluk ölçümlerinin uç değer analizi için özellikle dikkatle ele alınması (örneğin IQR temelli temizleme) önerilirken; şekil-temelli özniteliklerdeki nadir aykırılıklar model kararlılığını daha az etkileyebilir.

Veri Ön İşleme

IQR (Çeyrek Açıklığı) yöntemi

Veri setindeki aykırı değerleri belirlemek için kullanılan basit bir tekniktir. Önce verinin 1. çeyreği (Q1, %25'lik değer) ve 3. çeyreği (Q3, %75'lik değer) hesaplanır, bu iki değer arasındaki fark IQR'ı verir.

Daha sonra alt sınır olarak $Q1 - 1.5 \cdot IQR$, üst sınır olarak $Q3 + 1.5 \cdot IQR$ belirlenir. Veride bu eşiklerin dışında kalan noktalar (yani bunlardan küçük ya da büyük olan değerler) aykırı olarak kabul edilir ve analiz öncesi temizlenebilir ya da incelenebilir. Bu sayede uç değerlerin modele aşırı etki etmesi engellenir.

Uç değerleri objektif şekilde tanımlamak için IQR (Interquartile Range) yöntemini uyguladığında Q1 ve Q3 çeyrekler arasındaki farkı hesaplayıp alt/üst sınır eşiklerini belirlenmiştir. Bu sınırların dışındaki gözlemleri veri setinden çıkarılmıştır. 491 satır ve 9 sütundan oluşan tüm bu adımlar, makine öğrenmesi modellerinin temiz, dengeli ve tekrarlanabilir bir veri girişiyle en güvenilir sonuçları üretmesi sağlamıştır.

Veri temizleme yaptıktan sonra tüm değerler 'float' sayılarından oluşmuştur.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 491 entries, 0 to 490
Data columns (total 9 columns):
#   Column                                Non-Null Count  Dtype
---  ---                                -
0   cevre_ortalama                        491 non-null    float64
1   alan_ortalama                        491 non-null    float64
2   puruzsuzluk_ortalama                491 non-null    float64
3   kompaktlik_ortalama                 491 non-null    float64
4   konkavite_ortalama                  491 non-null    float64
5   konkav_nokta_sayisi_ortalama         491 non-null    float64
6   simetri_ortalama                    491 non-null    float64
7   fraktal_boyut_ortalama               491 non-null    float64
8   tani_1                              491 non-null    uint8
dtypes: float64(8), uint8(1)
memory usage: 31.3 KB
```

Verinin dağılımı, merkezi eğilim ve değişkenlik özelliklerini incelendiğinde;

- Her bir özelliğin hangi değer aralıklarında yoğunlaştığını ve dağılım biçimlerini net bir şekilde görebiliyor.
- Ortalama ve medyan değerler, modelin hangi değerler etrafında öğrenme yapacağını; standart sapma ise değişkenlerin ne kadar yayıldığını ortaya koyar.
- Özellikler arasındaki ölçek farklılıkları, mutlaka ölçeklendirme adımının (StandardScaler) gerekliliğini gösterir.
- Aykırı değerlerin varlığı, veri temizleme sürecinin (IQR yöntemi) model performansı üzerindeki kritik rolünü işaret eder.
- Bu bulgular, model seçimi ve hiperparametre ayarları yaparken daha sağlam ve dengeli kararlar almamıza imkân tanır.

	cevre_ortalama	alan_ortalama	puruzsuzluk_ortalama	simetri_ortalama	fraktal_boyut_ortalama
count	523.00	523.00	523.00	523.00	523.00
mean	92.19	658.64	0.10	0.18	0.06
std	24.38	353.62	0.01	0.03	0.01
min	43.79	143.50	0.05	0.11	0.05
25%	75.19	420.30	0.09	0.16	0.06
50%	86.91	555.10	0.10	0.18	0.06
75%	105.40	798.30	0.10	0.19	0.07
max	188.50	2501.00	0.16	0.30	0.10

	kompaktlik_ortalama	konkavite_ortalama	konkav_nokta_sayisi_ortalama \
count	523.00	523.00	523.00
mean	0.10	0.09	0.05
std	0.05	0.08	0.04
min	0.02	0.00	0.00
25%	0.06	0.03	0.02
50%	0.09	0.06	0.03
75%	0.13	0.13	0.07
max	0.35	0.43	0.19

	cevre_ortalama	alan_ortalama	puruzsuzluk_ortalama	kompaktlik_ortalama	konkavite_ortalama	konkav_nokta_sayisi_ortalama	simetri_ortalama	fraktal_boyut_ortalama
count	523	523	523	523	523	523	523	523
mean	92,19	658,64	0,1	0,1	0,09	0,05	0,18	0,06
std	24,38	353,62	0,01	0,05	0,08	0,04	0,03	0,01
min	43,79	143,5	0,05	0,02	0	0	0,11	0,05
25%	75,19	420,3	0,09	0,06	0,03	0,02	0,16	0,06
50%	86,91	555,1	0,1	0,09	0,06	0,03	0,18	0,06
75%	105,4	798,3	0,1	0,13	0,13	0,07	0,19	0,07
max	188,5	2501	0,16	0,35	0,43	0,19	0,3	0,1

Tablo 2 Verinin dağılımı ve merkezi eğilim

Veri setindeki her bir özelliğin

- “count”(gözlem sayısı) değeri 523’tür; bu, hiçbir eksik veri olmadığını ve tüm 523 gözlemin eksiksiz şekilde kaydedildiğini gösterir.
- “Mean” (ortalama) değerleri, örneğin çevre_ortalama için yaklaşık 92,19 ve alan_ortalama için yaklaşık 658,64, gözlemlerin genel eğilim noktalarını yansıtır.
- “Std” (standart sapma) ise çevre_ortalama’da 24,38 ve alan_ortalama’da 353,62 gibi yüksek değerlerle, bu ölçümlerin ortalamadan ne kadar saptığını ortaya koyar; pürüzsüzlük_ortalama gibi bazı özelliklerde ise çok daha düşük sapmalar gözlemlenir.
- “Min” (minimum) değerler, tümör boyutlarının en küçük ölçümlerini – örneğin çevre_ortalama için 43,79 – belirtir.
- “Max” (maksimum) değerler, veri setindeki en büyük tümör örneklerini – alan_ortalama için 2500,00 gibi – tanımlar.
- Bu beş istatistik, verinin eksiksizliğini, merkezi eğilimini, yayılımını ve uç değer sınırlarını kavramamıza yardımcı olur.

StandardScaler()


Makine öğrenmesi modellerine girdi olarak verilen sayısal özelliklerin aynı ölçeğe getirilmesi amacıyla kullanılan bir dönüştürücüdür. Her sütunun ortalamasını 0, standart sapmasını 1 olacak şekilde yeniden ölçeklendirir; bunun için önce her değerden ilgili özelliğin ortalaması çıkarılır, sonra bu fark ilgili özelliğin standart sapmasına bölünür. Böylece farklı birim ve büyüklükteki değişkenler modele eşit katkı sağlar, eğitim süreci daha dengeli ve hızlı ilerler.

Veri setinde çevre_ortalama ve alan_ortalama gibi bazı sütunlar, diğer özniteliklere göre çok daha yüksek sayısal değerlere sahiptir. Bu tür dengesizlikler, analiz sırasında bazı değişkenlerin modele daha baskın etki etmesine yol açabilir. Bu sorunu önlemek için tüm sayısal sütunlar StandardScaler() yöntemiyle ölçeklendirilir.


Bu işlem, her bir sayısal sütunun ortalamasının 0, standart sapmasının ise 1 olacak şekilde dönüştürülmesini sağlar. Böylece tüm öznitelikler model üzerinde eşit etkiye sahip olur.

cevre_ortalama	alan_ortalama	puruzsuzluk_ortalama	kompaktlik_ortalama	konkavite_ortalama	konkav_no_kta_sayisi_ortalama	simetri_ortalama	fraktal_boyut_ortalama	tani_1
1,47	1,24	1,65	3,48	2,94	2,84	2,28	2,33	1,00
1,93	2,32	-0,82	-0,45	0,04	0,67	0,03	-0,87	1,00
1,80	1,91	1,00	1,15	1,54	2,30	0,98	-0,39	1,00
-0,59	-0,82	3,42	3,61	2,14	1,66	2,94	5,06	1,00
0,80	0,56	1,55	1,99	1,20	1,59	1,33	1,58	1,00
1,80	2,10	0,17	0,02	0,87	1,37	-0,82	-1,27	1,00
-0,14	-0,22	0,14	-0,40	-0,24	0,03	0,30	-0,73	0,00
-0,23	-0,37	0,85	0,50	-0,52	-0,44	0,60	0,79	0,00
-1,38	-1,19	0,47	-0,73	-0,74	-0,73	0,04	0,93	0,00
0,54	0,24	0,83	2,21	1,68	1,44	2,65	1,11	1,00
2,13	2,58	-0,12	0,01	0,35	1,12	-0,13	-1,44	1,00
0,89	0,91	1,19	0,87	0,93	1,28	0,71	0,09	1,00

Tablo 3 Kanser veri setinin StandardScaler() edimiş hali



Alan_ortalama sütununun orijinal dağılımını gösteriyor. Ortalama yaklaşık 658,6 ve standart sapma yaklaşık 353,3 birim



StandardScaler ile z-skor normalizasyonu sonrası hâli yer alıyor; burada ortalama 0, standart sapma 1 olacak şekilde dönüştürülmüş dağılım görülüyor.


Korelasyon matrisi

Veri setindeki sayısal değişkenler arasındaki ikili doğrusal ilişkinin niceliksel bir özetidir. Her hücredeki değer -1 ile $+1$ arasında değişir; $+1$ tam pozitif ilişki, -1 tam negatif ilişki, 0 ise ilişkisizlik anlamına gelir. Yüksek mutlak korelasyon ($|r| > 0,8$) iki özelliğin büyük ölçüde aynı bilgiyi taşıdığını, dolayısıyla modellerde çoklu doğrusallık (multikolinearite) sorununa yol açabileceğini gösterir. Öte yandan, düşük korelasyonlu özellikler modele özgün varyasyon katarak sınıflandırma performansını iyileştirebilir. Bu nedenle korelasyon matrisi, hem gereksiz özniteliklerin elenmesi hem de boyut indirgeme yöntemlerinin planlanması için yol göstericidir.

Veri setindeki sekiz sayısal öznenin korelasyon matrisi şu önemli bulguları ortaya koymaktadır:

- Çevre_ortalama ile alan_ortalama arasındaki ilişki neredeyse mükemmel ($\approx 0,99$), yani bu iki değişken büyük ölçüde aynı boyut bilgisini yansıtıyor.
- Tümördeki çukurluk derecesini ölçen konkavite_ortalama ile konkav_nokta_sayısı_ortalama arasında da çok güçlü ($\approx 0,92$) bir bağ var.
- Kompaktlik_ortalama, hem çevre_ortalama ($\approx 0,89$) hem de konkavite_ortalama ($\approx 0,88$) ile yüksek korelasyona sahip; bu üç öznitelik de tümörün hacim ve şekil bütünlüğüyle ilgili benzer bilgileri tekrarlıyor.

- Pürüzsüzlük_ortalama, simetri_ortalama ve fraktal_boyut_ortalama daha düşük ve değişken ($\approx 0,30-0,60$) korelasyonlar sergiliyor; özellikle fraktal_boyut_ortalama, diğer tüm özniteliklerle $0,15$ 'in altında kaldığı için modele özgün varyasyon katıyor.
- Boyut-temelli ve çukurluk ölçümleri arasında çoklu doğrusallık riski bulunurken, pürüzsüzlük, simetri ve fraktal boyut gibi özellikler modele ilave bilgi sağlıyor.



- Pürüzsüzlük_ortalama, simetri_ortalama ve fraktal_boyut_ortalama daha düşük ve değişken ($\approx 0,30-0,60$) korelasyonlar sergiliyor;
- özellikle fraktal_boyut_ortalama, diğer tüm özniteliklerle 0,15'in altında kaldığı için modele özgün varyasyon katıyor.
- Boyut-temelli ve çukurluk ölçümleri arasında çoklu doğrusallık riski bulunurken, pürüzsüzlük, simetri ve fraktal boyut gibi özellikler modele ilave bilgi sağlıyor.

	cevre_ortalama	alan_ortalama	puruzsuzluk_ortalama	kompaktlik_ortalama	konkavite_ortalama	konkav_nokta_sayisi_ortalama	simetri_ortalama	fraktal_boyut_ortalama
cevre_ortalama	1	0,99	0,21	0,56	0,71	0,85	0,19	-0,27
alan_ortalama	0,99	1	0,17	0,5	0,68	0,82	0,15	-0,29
puruzsuzluk_ortalama	0,21	0,17	1	0,66	0,53	0,55	0,55	0,58
kompaktlik_ortalama	0,56	0,5	0,66	1	0,89	0,83	0,61	0,55
konkavite_ortalama	0,71	0,68	0,53	0,89	1	0,92	0,51	0,34
konkav_nokta_sayisi_ortalama	0,85	0,82	0,55	0,83	0,92	1	0,47	0,16
simetri_ortalama	0,19	0,15	0,55	0,61	0,51	0,47	1	0,49
fraktal_boyut_ortalama	-0,27	-0,29	0,58	0,55	0,34	0,16	0,49	1


Tablo 4 Korelasyon Matrisi

Isı haritası (heatmap)

İki boyutlu bir veri matrisindeki değerleri renk yoğunluklarıyla görselleştiren bir grafikdir. Her hücredeki renk, o hücredeki değerin veya değişkenler arası ilişkinin büyüklüğünü temsil eder; sıcak (kırmızı) tonlar yüksek, soğuk (mavi) tonlar düşük değer veya güçlü/ zayıf korelasyonu gösterir. Bu sayede, özellikle korelasyon matrisinde hangi değişken çiftlerinin güçlü veya zayıf ilişkili kurduğu hemen gözlemlenebilir.

Isı haritası, tümörün boyutuna dair ölçümler;

- Cevre_ortalama ile alan_ortalama arasında neredeyse tam pozitif korelasyon ($\approx 0,9$) gösterdi; bu iki değişken büyük ölçüde aynı bilgiyi taşıyor.
 - Çukurluk derecesini ölçen konkavite_ortalama ve konkav_nokta_sayisi_ortalama da yüksek ($\approx 0,9$) ilişki ile birbirini destekliyor. Kompaktlik_ortalama, hem boyut hem de çukurluk özellikleriyle güçlü bağlar kurarak ($\approx 0,8$) hacim ve şekil bütünlüğü hakkında tekrar eden veri sunuyor.
 - Pürüzsüzlük_ortalama, simetri_ortalama ve fraktal_boyut_ortalama daha ılımlı ($\approx 0,3-0,6$) korelasyonlarla özgün varyasyon taşıyor.
- Bu dağılım, çoklu doğrusallık riskini gösterir.




MAKİNE ÖĞRENMESİ MODELLEME YAKLAŞIMI

Veri, modelin genelleme yeteneğini objektif olarak ölçmek ve aşırı öğrenmeyi (overfitting) önlemek için eğitim ve test seti olarak ikiye bölünür.

Makine öğrenmesinde neden eğitim ve test çalışması yapılır?

Makine öğrenmesi, karmaşık veri desenlerini ve ilişkilerini elle tanımlamak yerine, bilgisayarın büyük veri kümelerinden otomatik olarak öğrenmesini sağlar. Geleneksel programlamada her kuralı elle kodlamak gerekirken; makine öğrenmesi verinin kendisinden model çıkararak öngörülerde bulunur, sınıflandırma yapar veya tahminlerde bulunur. Özellikle tıp, finans ve pazarlama gibi alanlarda veri hacmi ve özelliği arttıkça, uzmanların bile tüm örüntüleri görmesi ve kodlaması neredeyse imkânsız hale gelir. Makine öğrenmesi ile:

- Zaman kazandırır: Otomatik modelleme, karmaşık hesaplamaları hızla yapar.
- Daha yüksek doğruluk elde edilir: İnsan gözüyle fark edilemeyen ince ilişkileri yakalayıp daha isabetli tahminler sunar.
- Genelleme kabiliyeti kazanılır: Yeni, görülmemiş verilerde de tutarlı performans sağlar.
- Ölçeklenebilirlik sunar: Veri hacmi büyüdükçe sistemler otomatik öğrenmeye devam eder.
- Gerçek hayatta model, eğitim verisinden farklı yeni verilerle karşılaşır.
- Sadece eğitim verisindeki başarı, gerçek başarının garantisi değildir, model ezberlemiş (overfit) olabilir.



•Test seti, “yeni” veriye karşı güvenilir bir performans ölçümü sağlar ve gerçek dünyadaki kullanım öngörülerini doğrular.
Modeli eğitirken ve gerçek dünyada çalıştırırken görülebilecek başarının tutarlı ve güvenilir olmasını tercih edilir.


•**Eğitim Seti (%80)**

•Model, bu veriler üzerinde öğrenir. Özelliklerle hedef değişken arasındaki ilişkileri keşfeder ve parametrelerini ayarlar.
•Eğer tüm verinin tamamı eğitimde kullanılsaydı, model öğrendiği “(görmediği)” veriler üzerinde performansını ölçülemeyeceği için aşırı uyum (overfitting) riski artardı.

•**Test Seti (%20)**

•Model, test verilerini hiç görmeden önce eğitilir. Ardından bu veriler üzerinde tahmin yaparak gerçek başarısını ölçülür.
•Test seti, modellerin daha önce karşılaşmadığı veriler karşısında ne kadar iyi genelleme yaptığını gösterir.
Bu avantajlar, meme kanseri gibi kritik bir alanda hastalığı erken ve doğru teşhis edip, klinik karar destek sistemlerine entegre ederek hasta bakım kalitesinin yükseltilmesini mümkün kılar.

Makine Öğrenmesinde Eğitim ve Test Süreci



Kullanılan Algoritmalar:

- **Lojistik Regresyon (LR)**

Doğrusal bir karar sınırı kullanarak sınıflandırma yapan temel bir modeldir; her bir özelliğe ait katsayılar, pozitif veya negatif etki büyüklüğünü doğrudan yorumlanmasını olanak tanır.

Lineer bir model; karar sınırını lojistik fonksiyonla oluşturur. Doğrusal bir sınırla sınıfları ayırıyor.



En önemli özellikler:

1. konkavite_ortalama
2. kompaktlik_ortalama
3. konkav_nokta_sayısı_ortalama

- **K-Nearest Neighbors (KNN) yöntemi**

Test örneğini eğitim kümesindeki en yakın “K” komşunun etiketlerine bakarak sınıflandırır; mesafe ölçütü ve “K” değeri performansı belirler, ancak büyük veri setlerinde hesaplama yükü artabilir.

Komşuluk tabanlı, düzensiz sınırlar oluşturuyor. Komşulara dayalı, mesafe temelli sınıflandırma. Önem skoru hesaplanamaz, çünkü KNN doğrudan özellik ağırlığı vermez.



• Decision Tree (DT)

Veri üzerinde bir ağaç yapısı kurarak her düğümde en bilgilendirici özelliğe göre bölünme gerçekleştirir; yorumlanabilir ve hızlıdır, fakat derin ağaçlarda aşırı uyum (overfitting) riski taşır.

Dik dikey ve yatay bölünmelerle hiyerarşik karar kuralları gösteriyor. Özellik temelli karar düğümleriyle ağaç yapısı oluşturur.

En önemli özellikler:

1. konkav_nokta_sayısı_ortalama
2. alan_ortalama
3. konkavite_ortalama

• Random Forest (RF)


Birçok karar ağacını rastgele özellik alt kümeleri üzerinden eğitip sonuçlarını oylayarak birleştirir; böylece tek bir ağacın hatalarından kaçınır ve genelleme yeteneğini önemli ölçüde artırır.

Birden fazla karar ağacının oy çokluğuna dayalı toplu tahmini.


En önemli özellikler:

1. konkav_nokta_sayısı_ortalama
2. alan_ortalama
3. konkavite_ortalama

Veri setimizdeki çevre_ortalama ve alan_ortalama özellikleri kullanılarak eğitilen üç farklı karar ağacı (Tree-1, Tree-2, Tree-n), her biri Instance (yeni gözlem) üzerinde tahmin yapar. Ardından “Majority Voting” adımıyla en çok oy alan etiket Final Class (malign/benign) olarak belirlenir. Bu yöntem, tek bir ağacın hatalarını topluca azaltarak daha güvenilir sınıflandırma sağlar.




Random Forest Classification



• Gaussian Naive Bayes (NB)

Her bir özelliğin birbirinden bağımsız olduğunu varsayarak Bayes teoremiyle sınıflandırma yapar; normal dağılım varsayımı altında küçük veri setlerinde bile hızlı ve şaşırtıcı derecede iyi performans sergiler. Bayes teoremi ve normal dağılım varsayımı temellidir. Önem skoru hesaplanamaz. Gaussian Naive Bayes modelinin *cevre_ortalama* ve *alan_ortalama* özellikleri üzerinden her iki sınıf için (Benign ve Malign) öğrenilen Gauss dağılımlarını ve gerçek veri noktalarını gösterir.

- Kırmızı elmaslar: Benign vakalar, kırmızı kontur eğrileri benign sınıfın olasılık yoğunluğunu yansıtır.
- Mavi üçgenler: Malign vakalar, mavi kontur eğrileri malign sınıfın olasılık yoğunluğunu yansıtır.
- Kontur çizgileri, her sınıfın veri uzayındaki yoğunluk seviyelerini belirginleştirerek, karar sınırlarının nerede yer alabileceğini görsel olarak ortaya koyar




• Support Vector Machine (SVM)

Veriyi en geniş marjini sağlayacak şekilde bölen bir hiper düzlem bulur; doğrusal olmayan problemlerde RBF veya polinom çekirdekleriyle esnek sınırlar oluşturup karmaşık örüntüleri öğrenebilir.

SVM (linear kernel) modelinin *cevre_ortalama* ve *alan_ortalama* özellikleri üzerindeki karar sınırı ve marjinlerini gösteren grafik bulunuyor:




- Yeşil kareler: Benign (B=0) sınıfı örnekleri
- Turuncu daireler: Malign (M=1) sınıfı örnekleri
- Düz siyah çizgi: Sınıfları ayıran karar sınırı (*hyperplane*)
- Kesikli siyah çizgiler: Karar sınırına paralel marjin hatları (± 1 birim)
- Eksenler: Her iki özellik de StandardScaler ile ortalaması 0, standart sapması 1 olan ölçeğe dönüştürülmüştür.

Bu görsel, SVM'in en geniş marjini bulma prensibini ve iki özellik eksenindeki sınıflandırma ayrımını açıkça ortaya koyar.



Önem skoru

Makine öğrenmesi modelinin karar verme sürecinde her bir öznelik için ne kadar ağırlık atadığını sayısal olarak gösterir; yüksek bir önem skoru, o özelliğin sınıflandırma veya tahmin doğruluğu üzerinde kritik bir rol oynadığını, düşük bir skor ise katkısının daha sınırlı kaldığını işaret eder. Bu bilgi, eldeki veriden en anlamlı değişkenleri seçerek gereksiz veya yanıltıcı özellikleri elememize, böylece modelin hem hızını hem de genel performansını artırmamıza olanak tanır. Ayrıca, özellikle sağlık, finans veya hukuk gibi alanlarda bir modelin “neden” belirli kararlar verdiğini açıklamada rehberlik ederek şeffaflığı ve güvenilirliği güçlendirir. Sonuç olarak, özellik önem skorları hem veri hazırlama sürecinde hem de model değerlendirmede yol gösterici olarak daha kompakt, yorumlanabilir ve genelleme kabiliyeti yüksek sistemler geliştirmemizi sağlar.



Özellik	LR Importance	DT Importance	RF Importance
cevre_ortalama	0,34	0,04	0,02
alan_ortalama	0,45	0,28	0,3
pürüzsüzlük_ortalama	0,12	0,01	0,008
kompaktlik_ortalama	0,59	0,1	0,07
konkavite_ortalama	0,72	0,25	0,27
konkav_nokta_sayısı_ortalama	0,48	0,31	0,33
simetri_ortalama	0,08	0,008	0,006
fraktal_boyut_ortalama	0,06	0,004	0,004

Tablo 5 (LR: Lojistik Regresyon, DT: Karar Ağacı, RF: Random Forest) önem değerleri

- RF’de en yüksek önem (0.33) “konkav_nokta_sayısı_ortalama” → Random Forest’in en güçlü ayırt edici özelliği.
- En yüksek değer (0.59) “kompaktlik_ortalama” → Logistic Regression en çok güven veriyor.

Modeller farklı özelliklere farklı ağırlık veriyor.

- Logistic Regression “kompaktlik_ortalama”yı,
- Random Forest “konkav_nokta_sayısı_ortalama”yı,
- Karar Ağacı ise “alan_ortalama” ve “konkav_nokta_sayısı_ortalama”yı öncelikli görüyor.
- Zayıf özellikler: “fraktal_boyut_ortalama” üç modelde de çok düşük önem taşıyor.

Diğer üç yöntem (KNN, Naive Bayes, SVM)

- KNN, örnek tabanlı bir yöntem olduğu için “özellik katsayısı” kavramı yoktur.
- Naive Bayes, her özelliğin bağımsızlık varsayımı altında olasılık dağılımı kullandığından tek bir önem skoru çıkarmaz.
- SVM de (özellikle RBF çekirdekli) doğrusal olmayan bir sınır çizdiği için doğrudan bir coef_ veya feature_importances_ sunmaz.

MODEL PERFORMANS KARŞILAŞTIRMASI

Confusion matrix,


Sınıflandırma modellerinin tahmin sonuçlarını gerçek değerlerle karşılaştırarak dört kategoride toplar:

- True Positive (TP): Modelin “pozitif” dediği ve gerçekten pozitif olan örnekler.
- True Negative (TN): Modelin “negatif” dediği ve gerçekten negatif olan örnekler.
- False Positive (FP): Modelin “pozitif” dediği ancak aslında negatif olan örnekler (Type I hata).
- False Negative (FN): Modelin “negatif” dediği ancak aslında pozitif olan örnekler (Type II hata).

Bu matris, modelin hem doğru sınıflandırmalarını (TP, TN) hem de hangi yönlerde hata yaptığını (FP, FN) net olarak gösterir. Böylece sadece genel doğruluk (accuracy) değil, hassasiyet (precision), duyarlılık (recall) gibi detaylı performans metriklerinin hesaplanmasına imkân tanır.

Makine öğrenmesinde kullanılan yöntemlerde confusion Matrix’leri ortak incelendiğinde şu gözlemler öne çıkıyor:


1. True Positive (alt sağ hücre) ve True Negative (üst sol hücre) değerleri neredeyse tüm modellerde baskın; en yüksek doğru sınıflandırma oranları Random Forest ve SVM’de, hemen ardından Decision Tree’de görülüyor.
 2. False Positive (üst sağ) ve False Negative (alt sol) hataları en düşük seviyede, yani modelin hem “kanser” hem de “kanser değil” vakaları doğru tahmin etme başarısı oldukça yüksek.
 3. KNN ve Naive Bayes diğerlerine kıyasla biraz daha fazla FP/FN hatası yapmış; özellikle KNN’de bazı benign örnekler malign, bazı malign örnekler de benign olarak sınıflandırılmış.
 4. Logistic Regression dengeli bir performans sunuyor, hataları hem FP hem FN tarafında nispeten simetrik.
 5. Random Forest ise hem doğru pozitif hem doğru negatif sayısını en üst seviyeye taşıyarak, hataları minimuma indirmiş oluyor.
- Tüm sınıflandırıcılar test setinde güçlü sonuç verirken; Random Forest ve SVM, en az karışıklığa (confusion) sebep olan en tutarlı modeller olarak öne çıkıyor.



Model	True Negative (TN)	False Positive (FP)	False Negative (FN)	True Positive (TP)
LR	64	1	3	37
KNN	64	1	7	33
DT	61	4	1	39
RF	61	4	0	40
NB	61	4	3	37
SVM	65	0	8	32

Performans metriklerini hem çubuk grafik hem de yandaki tabloyla modellerin Accuracy, Precision, Recall, ve F1 Score değerlerini tek seferde görüntüledik:

- Random Forest (RF) tüm modellere eşit en yüksek Recall (1.0) ile öne çıkarken, Logistic Regression (LR) en iyi Precision ve yüksek Accuracy sağladı.
 - KNN ve SVM, Recall'da diğer modellere göre zayıf kaldığı görüldü.
 - NB dengeli bir performans sunarken, özellikle Precision ve Recall'da ortalamanın üzerinde sonuç verdi.
- Tek bir bakışta kıyaslamak için ideal görsel oluştu.



	Accuracy	Precision	Recall	F1 Score
LR	0.962	0.974	0.925	0.949
KNN	0.924	0.971	0.825	0.892
DT	0.952	0.907	0.975	0.94
RF	0.962	0.909	1.0	0.952
NB	0.933	0.902	0.925	0.914
SVM	0.924	1.0	0.8	0.889

Tablodaki sonuçlara göre:

- Logistic Regression (LR) ve Random Forest (RF), en yüksek Accuracy değerine (0.962) ulaşarak genel doğrulukta lider konumda.
 - LR, hem Precision (0.974) hem de F1 Score (0.949) açısından güçlü; RF ise Recall değerini 1.000'e çıkararak hiçbir malign vakayı kaçırmadığını gösteriyor.
 - Decision Tree (DT), Recall (0.975) ve F1 Score (0.940) ile malign vakaları tespit etmede çok başarılı, ancak Precision'ı RF ve LR'nin gerisinde (0.907).
 - KNN ve SVM, Accuracy'de (0.924) benzer performans sergilerken, KNN'de Recall (0.825) düşük kalıyor; SVM ise Precision'ı mükemmel (1.000) ama Recall'ı düşük (0.800).
 - Naive Bayes (NB) dengeli bir sonuç ortaya koyuyor (Accuracy 0.933, F1 Score 0.914), ancak hem Precision hem de Recall'da en üst modellerin bir miktar gerisinde.
- Sonuç olarak, erken teşhiste yanlış negatifleri minimize eden RF ve DT, genel doğruluk ve dengeyi koruyan LR, spesifik olarak yüksek kesinlik isteyen durumlar için ise SVM tercih edilebilir.

ROC (Receiver Operating Characteristic) eğrisi,

İkili sınıflandırma modellerinin farklı karar eşik değerlerinde ne kadar iyi ayrım yaptığını görselleştiren bir grafik tekniğidir.

- Yatay eksen $\rightarrow$ Yanlış Pozitif Oran

$$\text{(False Positive Rate = FPR = } \frac{FP}{FP + TN} \text{)}$$

- Dikey eksen $\rightarrow$ Doğru Pozitif Oran (True Positive Rate)
ya da duyarlılık = $TPR = \frac{TP}{TP + FN}$

çizilir.

AUC (Area Under the ROC Curve),


Eğrinin ideal konumu grafiğin sol üst köşesidir (FPR düşük, TPR yüksek). Eğrinin altındaki alan (AUC) 1'e ne kadar yakınsa, modelin pozitif ve negatif sınıfları ayırt etme kabiliyeti o kadar yüksektir.

- AUC = 0.5 değeri rastgele tahmine eşdeğerken,
- AUC > 0.8 iyi, AUC > 0.9 ise mükemmele yakın bir sınıflandırma performansını işaret eder.

Grafikteki ROC eğrilerine incelendiğinde,

- Random Forest (RF) modelinin eğrisi neredeyse sol üst köşeye yapışık kalarak AUC=1,00 düzeyinde mükemmele yakın ayırt ettiği görülüyor.


- Logistic Regression (LR) ve Naive Bayes (NB) modelleri de AUC≈0,98 ile çok yüksek performans gösteriyor.
 - Support Vector Machine (SVM) AUC≈0,95
 - Decision Tree (DT) sırasıyla AUC≈0,96 değerleriyle güçlü birer seçenek olarak öne çıkıyor. K-Nearest Neighbors (KNN) eğrisi ise diğerlerine kıyasla biraz daha aşağıda kalarak AUC≈0,94 değerinde kalıyor; bu da KNN'in yanlış pozitif oranı yükseldiğinde doğru pozitifleri yakalama oranının diğer modeller kadar hızlı artmadığını gösteriyor.
- Siyah kesikli çizgi, rastgele tahminin (AUC=0,50) referansını oluşturuyor; tüm modeller bu çizginin çok üzerinde kalarak gerçek vakaları tanıma konusundaki başarılarını gösteriyor.



SONUÇLAR VE YORUM


Genel olarak elde ettiğimiz bulgular, meme kanseri tanısında hem boyut hem de şekil temelli özelliklerin ayrıştırıcı gücünü açıkça ortaya koymaktadır. Geliştirilen modeller, Wisconsin Meme Kanseri veri setindeki morfolojik özniteliklerin kanserli–kanserli değil ayrımında yüksek başarı sağladığını göstermiştir. Ön işleme adımlarında aykırı değer temizliği, önem skorları, “konkav nokta sayısı”, “alan_ortalama” ve “konkavite”nin en belirleyici değişkenler olduğunu doğruladı ve StandardScaler ile ölçeklendirme sayesinde modellerimiz dengeli ve kararlı hale gelirken, EDA’da çevre_ortalama ile alan_ortalama arasındaki yüksek korelasyon ve shape özelliklerinin daha düşük varyanslı dağılımları dikkat çekti. Altı farklı sınıflandırıcı incelendiğinde,

- Random Forest: AUC=1,00, Recall=1,00 ile hiçbir kanserli vakayı kaçırmadı.
- Decision Tree: Recall=0,975, F1=0,940 ile güçlü ancak tek ağacın varyansından etkilenebilir.
- Logistic Regression: Accuracy=0,962, Precision=0,974, F1=0,949 ile en dengeli performansı sundu.



GELECEKTEKİ ÇALIŞMALAR

- Gelecek çalışmalarda hiperparametre optimizasyonu, veri zenginleştirme ve PCA gibi boyut indirgeme yöntemleriyle performansın daha da iyileştirilmesi hedeflenebilir.
- Kurum içi veya sertifikalı bulut sunucularında çalıştırılan model, sürekli telemetri ve yeniden eğitim mekanizmalarıyla klinik popülasyona uyarlanır ve ISO/FDA regülasyonlarına uygunluk süreçleri tamamlandıktan sonra resmi hasta bakım akışına dahil edilir. Böylece erken teşhiste zaman kazanılır, tanı doğruluğu artar ve klinik iş akışları pratik bir şekilde desteklenir. Patologlar ve onkologlar, laboratuvar raporuna ek bir “karar destek” notu olarak modeli rahatlıkla kullanabilirler. Yeni gelen verilerle periyodik yeniden eğitim (retraining) yapılarak model güncel klinik popülasyona adapte edilir.



KAYNAKÇA

[Meme Kanseri Wisconsin \(Tanı\) Veri Seti](#)